


# Exercícios Aula 002 - Preparação de Dados

Aula0002-Preparacao\_de\_dados.pptx

 [https://docs.google.com/presentation/d/1VYXv06p1vO\\_nLvU9N\\_oAqW-qd32fZwqx/edit?slide=id.p35#slide=id.p35](https://docs.google.com/presentation/d/1VYXv06p1vO_nLvU9N_oAqW-qd32fZwqx/edit?slide=id.p35#slide=id.p35)



PREPARAÇÃO DE DADOS

4086 – Aprendizagem de Máquina  
Profa. Valéria D. Feltrin  
PCC – DIN – UEM

Hugo Vinícius Fonseca Zuin — R.A.: 23000248-2

## 1) Conceitual – Importância da Preparação

A preparação de dados impacta diretamente a qualidade da informação fornecida ao modelo. Mesmo algoritmos sofisticados falham quando os dados contêm ruído, inconsistências, escalas incompatíveis ou desbalanceamento severo. Esse é o princípio do "Garbage In, Garbage Out": se os dados de entrada são ruins, a saída do modelo também será, independentemente de quão avançado seja o algoritmo escolhido. Por isso, a etapa de preparação pode influenciar mais no desempenho final do que a própria escolha do algoritmo.

## 2) Valores Ausentes

- a) As principais estratégias para tratar 25% de valores ausentes na variável **idade** são: remoção dos registros com valores ausentes, imputação pela média, mediana ou moda do atributo, e imputação por modelos preditivos (como um modelo de regressão treinado para estimar o valor ausente).
- b) Remover registros é inadequado quando há grande perda de dados (como neste caso, onde perderíamos 2.500 dos 10.000 registros) ou quando a ausência em si carrega informação relevante para o problema, por exemplo, se a razão de o valor estar ausente estiver correlacionada com o atributo meta.

## 3) Normalização vs Padronização

A Normalização (Min-Max) reescala os valores de um atributo para o intervalo [0, 1], usando a fórmula:

$$x' = \frac{x_i - \text{menor}}{\text{maior} - \text{menor}}$$

A Padronização (Z-score) transforma os dados para que tenham média 0 e desvio padrão 1, usando:

$$x' = \frac{x_i - \bar{x}}{s}$$

Algoritmos baseados em distância (como k-NN e SVM) exigem escalonamento. A normalização Min-Max é mais indicada quando não se conhece a distribuição dos dados ou a variância é baixa. A padronização é mais recomendada quando os dados seguem uma distribuição aproximadamente normal, pois preserva melhor a relação entre os valores.

---

## 4) Dados Categóricos

a) A variável `clima = {sol, chuva, nublado}` pode ser transformada via One-Hot Encoding, criando três atributos binários: `clima_sol`, `clima_chuva` e `clima_nublado`. Cada instância terá valor 1 no atributo correspondente ao seu valor original e 0 nos demais.

b) Usar codificação numérica simples (sol=0, chuva=1, nublado=2) pode induzir uma falsa relação ordinal, fazendo o modelo interpretar que "nublado > chuva > sol", o que não faz sentido para um atributo nominal.

---

## 5) Overfitting e Separação de Dados

Dividimos o dataset em três conjuntos com funções distintas: o **treino** é usado para ajustar (induzir) o modelo, a validação serve para ajustar hiperparâmetros e comparar configurações e o teste mede o desempenho final do modelo em dados nunca vistos.

Se utilizarmos o conjunto de teste durante o treinamento, ocorre vazamento de dados. O modelo acaba "memorizando" exemplos do teste, gerando uma avaliação irreal e otimista do desempenho, ele parecerá bom nos testes, mas terá desempenho ruim em dados reais novos.

---

## 6) Balanceamento de Classes

**a)** Com 95% classe A e 5% classe B, o modelo tende a prever sempre a classe majoritária (A), alcançando 95% de acurácia sem aprender nada sobre a classe B. O desempenho para a classe minoritária será muito baixo.

**b)** Duas técnicas para tratar esse desbalanceamento: Oversampling (como SMOTE, que gera instâncias sintéticas da classe minoritária) e Undersampling (remoção de instâncias da classe majoritária, como Random Undersampling ou Tomek Links).

---

## 7) Detecção de Outliers

**a)** Outliers são valores extremos que fogem significativamente do padrão geral dos dados. Podem ser decorrentes de erros de aquisição ou representar eventos raros legítimos.

**b)** Removê-los pode prejudicar o modelo quando os outliers representam eventos raros importantes para o problema, por exemplo, fraudes em transações financeiras.

**c)** Um método estatístico para detectá-los é o IQR (Intervalo Interquartil): calcula-se Q1 e Q3, e valores abaixo de  $Q1 - 1.5 \times IQR$  ou acima de  $Q3 + 1.5 \times IQR$  são considerados outliers. Outro método é o Z-score, que identifica como outliers os valores com Z-score acima de um limiar (geralmente  $|z| > 3$ ).

---

## 8) Feature Engineering

Criar a variável `idade` a partir de `data_nascimento` é melhor porque a idade é diretamente relevante ao modelo e mais fácil de interpretar. A data de nascimento em si é um dado temporal absoluto que não tem relação direta com o fenômeno a ser predito, o modelo precisaria "aprender" a calcular a diferença entre datas. Além disso, a idade reduz a complexidade temporal e evita problemas com formatos de data, facilitando o escalonamento e o uso em algoritmos numéricos.

---

## 9) Pipeline de Pré-processamento

Para um dataset com valores ausentes, dados categóricos, escalas diferentes e classes desbalanceadas, o pipeline seria:

1. **Tratar valores ausentes:** imputar pela média/mediana (numéricos) ou moda (categóricos), ou usar modelo preditivo

2. **Codificar variáveis categóricas:** aplicar One-Hot Encoding para atributos nominais ou Código Termômetro para ordinais
  3. **Escalar variáveis numéricas:** aplicar padronização (Z-score) ou normalização (Min-Max) para colocar todos os atributos na mesma escala
  4. **Balancear as classes:** aplicar técnica de reamostragem como SMOTE (oversampling) ou Tomek Links (undersampling)
  5. **Dividir em treino/validação/teste:** separar os dados antes de treinar o modelo, garantindo que não haja vazamento
- 

## 10) Estudo de Caso – Crédito Bancário

Para o dataset com `renda_mensal`, `idade`, `estado_civil`, `número_de_dependentes` e `histórico_de_inadimplência`:

1. **Verificar inconsistências**, checar valores impossíveis (idades negativas, rendas negativas)
2. **Tratar valores ausentes**, imputar `renda_mensal` e `idade` pela mediana (mais robusta a outliers), `estado_civil` pela moda
3. **Codificar `estado_civil`**, aplicar One-Hot Encoding (solteiro, casado, divorciado, etc.), pois é um atributo nominal
4. **Escalar `renda_mensal` e `idade`**, aplicar padronização (Z-score), já que possuem escalas muito diferentes (renda pode variar de centenas a dezenas de milhares, enquanto idade varia de ~18 a ~80)
5. **Avaliar desbalanceamento**, verificar a distribuição de `histórico_de_inadimplência` (atributo meta). Se houver desbalanceamento, aplicar SMOTE ou ajuste de pesos
6. **Separar os dados**, dividir em conjuntos de treino, validação e teste antes de qualquer treinamento

[https://docs.google.com/presentation/d/1VYXv06p1vO\\_nLvU9N\\_oAqW-qd32fZwqx/edit?slide=id.p35#slide=id.p35](https://docs.google.com/presentation/d/1VYXv06p1vO_nLvU9N_oAqW-qd32fZwqx/edit?slide=id.p35#slide=id.p35)